

Identificação de espécies nativas arbóreas do Cerrado via imagens multispectrais de drone

1st Enzo Z. Celentano

Departamento de Ciência da computação e Departamento de Engenharia elétrica

Universidade de Brasília

Brasília, Brasil

Abstract—Este trabalho investiga o uso de drones equipados com câmeras multispectrais para a identificação de espécies nativas do Cerrado. A combinação de processamento de imagens multispectrais e técnicas de *deep learning* é explorada para fornecer uma solução inovadora de monitoramento ambiental. O estudo foca em espécies de árvores da Reserva Ecológica do IBGE localizada no Distrito Federal, utilizando um modelo baseado em *transfer learning* e otimização da função de perda para melhorar a precisão na classificação das espécies. Apesar de ser obtido em um contexto de escassez de dados, o resultado final obtido de macro f1 score médio de 0.63 mostra que a abordagem proposta melhora significativamente a acurácia da identificação em comparação com métodos baseados em imagens RGB e demonstra o potencial dessas técnicas na preservação da biodiversidade do Cerrado.

I. INTRODUÇÃO

O Cerrado, o segundo maior bioma da América do Sul, é amplamente reconhecido por sua rica biodiversidade e por ser um dos 36 hotspots de biodiversidade do planeta [1]. Com uma flora e fauna únicas, o Cerrado abriga inúmeras espécies endêmicas, desempenhando um papel fundamental na regulação do ciclo hidrológico e na manutenção da biodiversidade global. Entretanto, essa vasta riqueza natural tem sido ameaçada por atividades humanas, como a expansão agrícola, o desmatamento e a urbanização descontrolada. Estima-se que cerca de 50% de sua cobertura original já tenha sido destruída, resultando em uma perda considerável de habitats naturais e, consequentemente, na diminuição da biodiversidade [2].

Diante desse cenário alarmante, torna-se imperativa a criação de novas tecnologias e metodologias que auxiliem na preservação e recuperação do Cerrado [3] [4]. O monitoramento eficaz das espécies nativas é crucial para a preservação da biodiversidade remanescente e para a implementação de políticas de conservação mais eficientes. Nesse contexto, o uso de drones equipados com câmeras multispectrais surge como uma solução inovadora, permitindo a coleta de dados em larga escala e de forma não invasiva. A análise de imagens multispectrais, combinada com índices de vegetação, pode proporcionar insights valiosos sobre a saúde da vegetação [5] e a distribuição de espécies nativas. [6]

Este estudo visa explorar o potencial de drones multispectrais no monitoramento e identificação de espécies nativas do Cerrado. Através da aplicação de técnicas de processamento de imagens, como a correção de distorção e o alinhamento de bandas espectrais, busca-se garantir uma análise precisa

e confiável da vegetação local. Ao fornecer uma base tecnológica para o monitoramento do Cerrado, espera-se contribuir para a preservação desse bioma ameaçado e para a mitigação dos impactos da degradação ambiental.

Adicionalmente, este trabalho apresenta três avanços no tema da pesquisa:

- A proposição inicial de análises que envolvem *deep learning* e espécies nativas do Cerrado, visto que, até onde sabemos, ainda não existem estudos que utilizem modelos de aprendizado de máquina para a detecção dessas espécies nativas.
- A introdução de um novo método para o pré-processamento de imagens multispectrais, demonstrando que essa abordagem pode melhorar os métodos tradicionais, que geralmente utilizam apenas imagens RGB.
- A proposição de uma função de perda customizada, baseada na *sigmoid focal loss*, que otimiza o hiperparâmetro *gamma* ao longo do treinamento, adaptando-se à taxa de aprendizado do modelo e melhorando sua performance.

Com essas inovações, foram estabelecidas quatro espécies nativas do Cerrado como exemplo, utilizando um modelo de *Deep Learning*, o que reforça a aplicabilidade prática das técnicas desenvolvidas para a preservação da biodiversidade desse bioma.

II. MATERIAIS E MÉTODOS

O processo geral de coleta de dados e predição de espécies via sensoriamento remoto pode ser resumido conforme a Figura 2. Como visualizado, as fotografias aéreas foram obtidas a partir de voos realizados pelo drone Mavic 3M, e essas fotos são posteriormente pré-processadas.

Se a tarefa for a de detecção de espécies, o modelo treinado identifica as árvores por suas respectivas espécies. Caso contrário, as fotos processadas são rotuladas e divididas em treino, validação e teste. O treinamento é realizado com as fotos processadas, que também passam por técnicas de aumento de dados. A cada época de treino, o *dataset* de validação é utilizado para ajuste dos hiperparâmetros do modelo.

Finalmente, o modelo com a menor perda no conjunto de validação é selecionado para a detecção de árvores no *dataset* de teste. Nesta seção, serão explicados detalhadamente os processos envolvidos.




Fig. 1: Espécies classificadas pelo modelo




Fig. 2: Fluxograma sobre como são realizadas as proposições de áreas com espécies

A. Aquisição de Imagens

1) *Área de Estudo*: Este estudo foi conduzido na Reserva Ecológica do IBGE, localizada no Distrito Federal, Brasil. Esta região faz parte do Cerrado, um bioma caracterizado por sua biodiversidade única, mas que tem sido vulnerável a diversas pressões ambientais nas últimas décadas. A área total da reserva é de aproximadamente 1.300 hectares, com uma circunferência de cerca de 14 km. A vegetação predominante na área de estudo é composta principalmente por espécies nativas do Cerrado, como *Tachigali subvelutina*, *Qualea grandiflora*, *Dalbergia miscolobium*, *Eriotheca pubescens*, *Didymopanax macrocarpus*, *Inga laurina*, *Styrax ferrugineus*, *Caryocar brasiliense*, *Miconia albicans*, *Solanum lycocarpum*, *Machaerium opacum*, *Byrsonima pachyphylla*, *Enterolobium gummiferum*, *Vochysia thyrsoidea*, *Syagrus flexuosa*, entre

outras. Muitas dessas espécies são sensíveis às mudanças ambientais, o que torna a reserva um local ideal para adquirir dados de imagens de vegetação e monitorar os impactos ambientais.

O voo para obtenção das imagens ocorreu em 28/08/2024, entre 14:17 e 14:33, durante o inverno. Foram capturadas 1.855 imagens multiespectrais, embora apenas uma parte tenha sido rotulada em campo com as espécies presentes. No total, 16 espécies foram classificadas pelos biólogos, das quais quatro apresentaram um número suficiente de rótulos para serem utilizadas para aprendizado de máquina.

Até onde sabemos, ainda não existem estudos detalhados sobre a utilização de imagens multiespectrais para a detecção de espécies nativas do Cerrado. Com o objetivo de preservar a biodiversidade local, a área foi selecionada como objeto de estudo para a coleta de dados de sensoriamento remoto, visando identificar e monitorar mudanças na cobertura vegetal e explorar novas formas de monitoramento dessa área rica em biodiversidade.

2) *Equipamentos de Estudo*: Neste estudo, foi utilizado o drone multiespectral DJI Mavic 3M [7] para a coleta de fotografias aéreas multiespectrais. O DJI Mavic 3M é um drone de asa rotativa com quatro hélices, projetado para ser de fácil operação, permitindo um controle preciso de voo, inclusive em pontos fixos, o que facilita a captura de imagens aéreas detalhadas. O Mavic 3M está equipado com uma câmera multiespectral que captura imagens em quatro bandas espectrais: verde, vermelho, NIR (infravermelho próximo) e red edge (borda do vermelho), além de uma câmera adicional que captura imagens no formato RGB.

Essas câmeras permitem a aquisição de imagens de alta resolução, ideais para monitoramento ambiental e análise da vegetação. O drone também possui um sensor de luz solar integrado, que ajusta automaticamente os parâmetros da câmera para garantir a qualidade das imagens sob diferentes condições de iluminação. As imagens obtidas, tanto no formato RGB quanto multiespectral, contêm metadados que podem ser utilizados para correção de efeitos fotográficos, os quais serão discutidos mais detalhadamente na subseção a seguir.




Fig. 3: Área da Reserva onde foram conduzidos os voos

B. Pré-processamento e Aumento de Imagens

1) *Correção de Vinhetagem*: O passo inicial envolveu a correção do efeito de vinhetagem. Os parâmetros para o modelo foram extraídos dos metadados XML embutidos nos arquivos de imagem pelas câmeras. Aplicamos a correção de vinhetagem na imagem de entrada $I(x, y)$ conforme descrito na Eq. (1).

$$I(x, y) \times (k[5] \cdot r^6 + k[4] \cdot r^5 + \dots + k[0] \cdot r + 1.0) \quad (1)$$

Aqui, k representa os coeficientes polinomiais para correção de vinhetagem, também encontrados nos metadados XML. A variável r é a distância entre o pixel (x, y) e o centro da vinheta, calculada como:

$$r = \sqrt{(x - \text{Centro}_X)^2 + (y - \text{Centro}_Y)^2} \quad (2)$$

2) *Correção de Distorção*: A correção de distorção é um passo crucial no processamento de imagens, particularmente quando se trata de imagens capturadas por câmeras com lentes angulares, como a que o drone Mavic 3M possui. Essas câmeras frequentemente introduzem distorções geométricas que precisam ser corrigidas para obter uma representação precisa da imagem e medições corretas [8]. Esses parâmetros incluem os parâmetros intrínsecos da câmera, que definem as características internas da câmera e são essenciais para a correção de distorção:

- **fx, fy**: Distâncias focais da câmera nos eixos x e y, respectivamente.
- **cx, cy**: Coordenadas do centro óptico do sensor de imagem.

Além desses parâmetros intrínsecos, o processo de correção de distorção utiliza os coeficientes polinomiais representados pela matriz K , anteriormente usados na correção de vinhetagem. Esses coeficientes modelam o padrão de distorção da lente da câmera. Os parâmetros intrínsecos da câmera que são indicados pelo fabricante e os parâmetros de correção de vinhetagem (Centro_X e Centro_Y) foram usados para construir a matriz da câmera para correção de distorção. A matriz da câmera é dada por:

$$\begin{bmatrix} fx & 0 & cx \\ 0 & fy & cy \\ 0 & 0 & 1 \end{bmatrix}$$

3) *Alinhamento das diferenças de fase e rotação*: A matriz de homografia, presente nos metadados de cada imagem, representa uma transformação projetiva que mapeia o plano de imagem físico individual para um plano de imagem ideal. Essa transformação é fundamental para alinhar imagens obtidas em diferentes bandas espectrais, especialmente quando as capturas são realizadas em modo de sobrevoo, onde podem ocorrer variações de posição e orientação. A correção dessas discrepâncias é realizada através da seguinte equação, que fornece as coordenadas do ponto de destino (dst) em função das coordenadas de origem (x, y) :

$$dst(x, y) = \left(\frac{H_{11}x + H_{12}y + H_{13}}{H_{31}x + H_{32}y + H_{33}}, \frac{H_{21}x + H_{22}y + H_{23}}{H_{31}x + H_{32}y + H_{33}} \right) \quad (3)$$

Esta abordagem permite que as imagens de diferentes bandas sejam comparadas de forma consistente.

4) *Normalização e Redimensionamento de Imagens*: Para garantir consistência entre os diferentes canais espectrais, os canais vermelho, borda vermelha, NIR (Infravermelho Próximo) e verde, que possuem valores de 0 a 65535, foram normalizados para corresponder à faixa de 8 bits dos canais RGB, variando de 0 a 255. Esse processo de normalização alinha a faixa de dados entre todos os canais, facilitando um processamento mais preciso e eficiente no modelo RetinaNet.

Além disso, todas as imagens RGB foram redimensionadas de 5280×3956 para 2570×1925 para garantir compatibilidade com as etapas subsequentes de processamento.

5) *Alinhamento de Imagens*: O erro de posição nas imagens, causado pelas diferentes distâncias entre as lentes da câmera para cada espectrômetro na câmera multiespectral, foi corrigido utilizando uma série de técnicas de processamento de imagens.

Primeiramente, a suavização Gaussiana foi aplicada a cada imagem espectral para reduzir o ruído e melhorar a detecção de características.

Em seguida, foi utilizado o algoritmo Sobel para a detecção de bordas, a fim de identificar características significativas dentro de cada imagem espectral [10]. Ao destacar os limites dos objetos, a detecção de bordas contribui para a localização precisa de pontos característicos entre as imagens.

Finalmente, a transformada do Coeficiente de Correlação Aprimorado (ECC) foi aplicada para alinhar cada imagem espectral em relação à imagem RGB. Este método envolve a extração de pontos de características utilizando o método SIFT [9] e sua correspondência com a imagem multispectral de referência da banda verde. Uma matriz de homografia é calculada usando a técnica de estimativa RANSAC com base nesses pontos característicos. Após a obtenção da matriz de homografia precisa H , todos os pixels da imagem são convertidos e mapeados por distorção em relação à imagem multispectral da banda verde. Essa transformação alinha as imagens RGB e multispectrais, ajustando as diferenças de perspectiva e posição entre as imagens, com o objetivo de que apresentem a mesma área de cobertura vegetal, conforme exemplificado na Fig. 4.

$$\begin{bmatrix} x_1 \\ y_1 \\ 1 \end{bmatrix} = H \begin{bmatrix} x_2 \\ y_2 \\ 1 \end{bmatrix} = \begin{bmatrix} h_{00} & h_{01} & h_{02} \\ h_{10} & h_{11} & h_{12} \\ h_{20} & h_{21} & h_{22} \end{bmatrix} \begin{bmatrix} x_2 \\ y_2 \\ 1 \end{bmatrix} \quad (4)$$

6) *Redução de Dimensionalidade*: Com o intuito de criar uma metodologia viável para ambientes com capacidades computacionais limitadas, decidiu-se reduzir as dimensões da imagem com 7 canais para 3 canais. Como o modelo RetinaNet foi projetado para lidar com imagens de três canais, a Análise de Componentes Principais (ACP) [11] foi aplicada às imagens alinhadas. A ACP é uma técnica de redução de dimensionalidade que transforma o conjunto de dados original em um novo conjunto de variáveis não correlacionadas, conhecidas como componentes principais, ordenadas pela quantidade de variância que explicam.

Ao aplicar a ACP às imagens empilhadas de sete bandas, conseguimos reduzir a dimensionalidade para três canais, mantendo as características mais significativas [12]. Essa transformação garantiu compatibilidade com a arquitetura do RetinaNet. Matematicamente, a ACP é expressa da seguinte forma:

$$\mathbf{Z} = \mathbf{X}\mathbf{W} \quad (5)$$

onde $\mathbf{Z}$ é a matriz de componentes principais, $\mathbf{X}$ é a matriz de dados centrada, e $\mathbf{W}$ é a matriz de autovetores (eixos principais) da matriz de covariância de $\mathbf{X}$. Os componentes principais são combinações lineares das variáveis originais, capturando as direções de máxima variância nos dados.

7) *Aumento de Imagens*: Uma vez que as imagens de três canais foram preparadas, elas foram divididas em conjuntos de dados para treinamento, validação e teste em uma proporção de 6:1:3. Essa divisão assegura que o modelo seja treinado com um conjunto de dados robusto, ao mesmo tempo em que possui dados separados para validação e teste para avaliar seu desempenho.

Para aumentar o tamanho e a diversidade do conjunto de treinamento, foram aplicadas técnicas de aumento de dados [13]. A partir do conjunto inicial de 97 imagens (pós redução de dimensionalidade) de treinamento, um total de 217 imagens foram geradas por meio de aumento. Esse processo envolveu técnicas como espelhamento, rotação e crops com zoom de 0% a 15%, que ajudam a aumentar a variabilidade do conjunto de dados e a melhorar a capacidade do modelo de generalizar para dados não vistos. Ao aumentar o conjunto de dados, o modelo é exposto a uma gama mais ampla de cenários, melhorando sua robustez e precisão.

C. Rotulagem das Espécies de Árvores

Em colaboração com biólogos do IBGE, quatro espécies de árvores foram identificadas e anotadas dentro da área de estudo. Esse esforço colaborativo garantiu a precisão na identificação das espécies, aproveitando a expertise dos biólogos no reconhecimento e categorização das espécies presentes. As anotações fornecem um conjunto de dados inicial para o treinamento, validação e teste do modelo. Essas anotações servem como uma base crítica para o desenvolvimento de um sistema confiável de detecção e classificação de espécies. Embora ainda seja um conjunto pequeno, já contribui significativamente para a pesquisa ecológica e os esforços de conservação na região.

D. Detecção de Objetos Baseada em CNN

Neste estudo, as imagens RGB e multispectrais e os índices de vegetação, mostrados na Fig. 4, foram considerados como dados de entrada para a detecção de objetos baseada em uma CNN. O modelo utilizado para detectar espécies de árvores é baseado em uma rede neural convolucional (CNN) [15] e consiste em uma estrutura de rede em duas etapas, que combina uma *Region Proposal Network* (RPN), que extrai as propostas de regiões, e uma R-CNN, que realiza a classificação e a predição de detecção.

A função de perda, que é uma função que indica a diferença entre o valor previsto e o valor real (*ground truth*), é apresentada em (10) e converge para o valor mínimo durante o treinamento. O *Adam Optimizer*, utilizado para convergir a função de perda para o valor mínimo, realiza o processo de otimização por meio do *stochastic gradient descent*, baseado na quantidade de gradiente do passado [16].

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*) \quad (6)$$

A seguir, são descritos os argumentos das variáveis na equação 6. Aqui, i é o índice da âncora dentro do *minibatch*; p_i é a predição de se a âncora i é um objeto ou fundo; p_i^* é o rótulo real (*ground-truth*) igual a 1, onde 1 significa que a âncora é positiva e 0 significa que a âncora é negativa; t_i é o vetor que contém as quatro coordenadas da caixa delimitadora; t_i^* é a caixa delimitadora real associada a uma âncora positiva;




Fig. 4: Imagens RGB e multispectrais.




Fig. 5: Exemplo de redução de dimensionalidade para imagem com 7 camadas

L_{cls} é a perda logarítmica (objeto ou não); L_{reg} é a função de perda *smooth L1* (utilizada apenas em âncoras positivas, $p_i^* = 1$); e N_{cls} é a normalização, que equivale ao tamanho do *minibatch*, enquanto L_{reg} também é normalizado pelo número de localizações de âncoras, onde λ é igual a 10 por padrão.

A equação a seguir descreve a função *smooth L1*, conforme descrito previamente na equação 6:

$$SmoothL1(x) = \begin{cases} 0.5x^2, & \text{se } |x| < 1 \\ |x| - 0.5, & \text{caso contrário.} \end{cases} \quad (7)$$

1) *Função de perda focal customizada*: Um aspecto único do RetinaNet é a sua *função de perda focal* [14], que aborda o problema do desequilíbrio de classes durante o treinamento. Em muitas tarefas de detecção de objetos, há um desequilíbrio significativo entre os objetos em primeiro plano e as regiões de fundo. A função de perda focal diminui a contribuição da perda em exemplos fáceis de classificar e se concentra mais em exemplos difíceis, melhorando, assim, a precisão e o *recall* do modelo na detecção de áreas de interesse.

Com o intuito de aprimorar a classificação de cada espécie de árvore neste estudo, foram feitas algumas alterações na função de perda na cabeça de classificação do modelo utilizado, especificamente no hiperparâmetro γ .

O hiperparâmetro γ modifica como o modelo trata exemplos difíceis e fáceis. Em tarefas de detecção de objetos, exemplos fáceis são aqueles em que a rede consegue classificar corretamente com alta confiança desde o início. No entanto, esses exemplos podem dominar o processo de treinamento, levando a uma convergência subótima. O γ ajusta a contribuição dos exemplos fáceis à função de perda, penalizando menos esses casos e direcionando o aprendizado para exemplos mais difíceis, onde o modelo ainda tem mais incertezas. Isso resulta

em uma melhora no desempenho para casos desafiadores, como espécies que compartilham características visuais semelhantes.

Dessa forma, propomos uma mudança dinâmica no valor de γ ao longo do treinamento:

$$\gamma_t = \gamma_0 + \left(\frac{lr \cdot 10}{C} \right) \cdot \exp\left(\frac{t}{T}\right) \quad (8)$$

Onde:

- γ_t é o valor atualizado do hiperparâmetro na época t .
- γ_0 é o valor inicial do hiperparâmetro no início do treinamento.
- C é o número de classes.
- t é a época atual.
- T é o número total de épocas no treinamento.
- lr é a taxa de aprendizado inicial do modelo.

Essas equações permitem que γ cresça exponencialmente conforme o treinamento avança, promovendo um foco dinâmico nos exemplos mais difíceis e diminuindo o impacto de exemplos em que o modelo já tem confiança.

E. Índice de avaliação

A avaliação da performance do modelo é baseada em duas condições que precisam ser satisfeitas para que uma predição seja considerada correta. A primeira condição é o cálculo da Interseção sobre a União, também conhecido como *Intersection over Union* (IoU), descrito pela equação 9. A IoU é a razão entre a área de interseção entre o objeto predito e o objeto de referência (também chamado de *ground-truth*) sobre a área da união desses dois objetos. Considerou-se que o valor de IoU é satisfatório quando é maior ou igual a 0.4.

A segunda condição é que a classe do objeto predito deve ser a mesma que a classe do objeto de referência. Depois que essas duas condições são atendidas, o objeto de referência correspondente é listado, e os valores de precisão (*precision*) e revocação (*recall*) são calculados conforme as equações 10 e 11, respectivamente.

Nas equações 11 e 10, TP representa os verdadeiros positivos (*true positives*), FP os falsos positivos (*false positives*), e FN os falsos negativos (*false negatives*). "Verdadeiro" refere-se à correspondência com o *ground-truth*, enquanto "Falso" refere-se à não correspondência. Já "Positivo" é a previsão correta, e "Negativo" a previsão incorreta.

$$IoU = \frac{\text{Área de Interseção}}{\text{Área de União}} \quad (9)$$

$$\text{Precisão} = \frac{TP}{TP + FP} \quad (10)$$

$$\text{Revocação} = \frac{TP}{TP + FN} \quad (11)$$

Além disso, o F1-Score é a métrica crucial que foi utilizada para avaliação do modelo, visto que a classificação de muitas classes pode ser bem avaliada dessa maneira. Essa métrica está descrita pela equação 12. Ele representa a média harmônica entre precisão e revocação, sendo útil em cenários onde há desequilíbrio entre classes. A fórmula para o cálculo do F1-Score é a seguinte:

$$F1 = 2 \cdot \frac{P \cdot R}{P + R} \quad (12)$$

Na equação 12, P refere-se à precisão, ou seja, a fração de verdadeiros positivos sobre o total de previsões positivas (verdadeiros positivos mais falsos positivos). Já R é a revocação, a fração de verdadeiros positivos sobre o total de instâncias relevantes (verdadeiros positivos mais falsos negativos). O F1-Score equilibra precisão e revocação em uma única métrica, sendo especialmente útil quando há um desequilíbrio entre classes, pois penaliza fortemente a presença de falsos positivos ou falsos negativos.

Para avaliação entre diferentes modelos de rede, também será utilizada a equação do macro F1-Score, que pode ser calculado conforme a fórmula:

$$\text{Macro F1-Score} = \frac{1}{N} \sum_{i=1}^N F1_i \quad (13)$$

Onde N é o número total de classes e $F1_i$ é o F1-Score da i -ésima classe. O Macro F1-Score é a média aritmética simples do F1-Score calculado para cada classe, tratando todas as classes igualmente, independentemente de seu tamanho ou frequência.

Para este estudo, o F1-Score será utilizado como a principal métrica de avaliação do modelo. Ao calcular o F1-Score para cada classe, obtemos o macro F1-Score, que é a média aritmética dos F1-Scores individuais de todas as classes. Isso permite uma visão geral do desempenho do modelo em relação a todas as categorias de espécies identificadas. Tal métrica foi escolhida, pois algumas espécies possuem mais indivíduos que outras e, em casos como esse, o macro F1-Score consegue medir o desempenho geral do modelo, mesmo com classes desbalanceadas.

III. RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados obtidos a partir do treinamento e teste das imagens multicanais pré-processadas pelo modelo proposto. O índice de avaliação F1-score, utilizado como métrica principal, demonstrou o sucesso do modelo que

emprega imagens multicanais e otimização da função de perda, em comparação com outras abordagens testadas.

É importante destacar que muitos dos resultados ainda são preliminares, sugerindo que estudos futuros, com maior volume de dados, podem melhorar significativamente o desempenho do modelo. Ainda assim, a análise dos resultados obtidos indica que o uso de dados multispectrais, aliados a técnicas de otimização, pode contribuir para um monitoramento mais preciso de espécies nativas do Cerrado.

A. Análise do modelo de treinamento

Para o desenvolvimento da rede neural proposta, foi utilizada a linguagem Python, aproveitando-se das bibliotecas *DeepForest* e *PyTorch* para a implementação do modelo. A arquitetura escolhida para a tarefa de classificação de espécies no Cerrado foi baseada no modelo *resnet50-fpn*, cujos pesos pré-treinados foram empregados por meio da técnica de *transfer learning*, permitindo que o modelo se adaptasse ao nosso conjunto de dados com maior eficiência.

O uso de *transfer learning* possibilitou que o modelo fosse extremamente leve do ponto de vista computacional, necessitando apenas de uma única GPU *p100* para realizar o treinamento completo. Todo o processo de treinamento, composto por 150 épocas, foi finalizado em cerca de uma hora, o que demonstra a viabilidade do modelo para aplicações em ambientes com recursos computacionais limitados.

O conjunto de dados utilizado foi relativamente pequeno, contendo apenas 87 imagens rotuladas de espécies nativas do Cerrado. Apesar do número de imagens limitado, os resultados alcançados demonstraram que a abordagem adotada foi eficiente na identificação das espécies, reforçando a aplicabilidade de técnicas de aprendizado profundo mesmo em contextos com restrições de dados.

B. Resultado de Inferência

Foram realizados dois testes independentes para cada variação de entrada e modelo, selecionando-se os melhores e piores modelos com base no macro F1-score de cada um. Conforme evidenciado nas tabelas I, II e III, as alterações propostas, tanto na função de perda quanto na utilização de imagens multicanais, resultaram em um aumento significativo do macro F1-score. Esse resultado é relevante, pois algumas espécies possuem significativamente menos indivíduos do que outras no dataset utilizado.

Uma interpretação gráfica desses resultados pode ser observada na Figura 6a e 6b. Ao utilizar imagens no formato RGB, o modelo demonstrou maior precisão na identificação da espécie *Vochysia thyrsoidea*, que se destaca visualmente em relação à vegetação circundante. Contudo, com a introdução de imagens multicanais, pré-processadas por meio da análise de componentes principais, o modelo foi capaz de identificar com maior acurácia vegetações com características mais semelhantes.

Conforme pode ser observado na tabela IV, o macro f1-score médio final obtido foi de **0.63** para o modelo proposto.

Tabela I: Resultado do índice de avaliação de acordo com a espécie, para imagens **RGB** e modelo **sem** otimização da função de perda

Espécie	Melhor			Pior		
	Precisão	Revogação	F1-score	Precisão	Revogação	F1-score
<i>Blepharocalyx salicifolius</i>	0.95	0.53	0.69	0.95	0.47	0.64
<i>Byrsonima pachyphylla</i>	0.25	0.98	0.40	0.43	0.75	0.54
<i>Enterolobium gummiferum</i>	0.40	0.97	0.57	0.25	0.66	0.37
<i>Vochysia thyrsoidea</i>	0.97	0.40	0.57	0.43	0.30	0.35
Macro F1	0.56			0.48		

Tabela II: Resultado do índice de avaliação de acordo com a espécie, para imagens **multispectrais** e modelo **sem** otimização da função de perda

Espécie	Melhor			Pior		
	Precisão	Revogação	F1-score	Precisão	Revogação	F1-score
<i>Blepharocalyx salicifolius</i>	0.70	0.98	0.82	0.77	0.98	0.87
<i>Byrsonima pachyphylla</i>	0.75	0.60	0.67	0.50	0.60	0.54
<i>Enterolobium gummiferum</i>	0.55	0.62	0.59	0.50	0.75	0.60
<i>Vochysia thyrsoidea</i>	0.42	0.30	0.35	0.50	0.18	0.26
Macro F1	0.61			0.57		

Tabela III: Resultado do índice de avaliação de acordo com a espécie, para imagens **multispectrais** e modelo **com** otimização da função de perda

Espécie	Melhor			Pior		
	Precisão	Revogação	F1-score	Precisão	Revogação	F1-score
<i>Blepharocalyx salicifolius</i>	0.77	0.95	0.86	0.88	0.98	0.94
<i>Byrsonima pachyphylla</i>	0.75	0.50	0.60	0.50	0.67	0.57
<i>Enterolobium gummiferum</i>	0.54	0.86	0.66	0.50	0.63	0.55
<i>Vochysia thyrsoidea</i>	0.75	0.34	0.46	0.50	0.27	0.36
Macro F1	0.65			0.60		

Tabela IV: Macro F1-score médio obtido em cada modelo

Modelo	Macro F1-score (Médio)
RGB	0.52
Multispectrais (sem otimização)	0.59
Multispectrais (com otimização)	0.63


IV. CONCLUSÃO

Neste estudo, investigamos a aplicação de imagens multicanais e técnicas de aprendizado profundo para o monitoramento e identificação de espécies nativas do Cerrado. O uso de drones equipados com câmeras multiespectrais, aliado a abordagens de *transfer learning* e otimização da função de perda, mostrou-se promissor na melhoria da acurácia na detecção de espécies em comparação com métodos baseados apenas em imagens RGB.


Os resultados obtidos, medidos pelo F1-score, indicam que o modelo proposto, ao incorporar imagens multicanais e a função de perda otimizada, foi capaz de melhorar significativamente o desempenho na tarefa de classificação das espécies. Em particular, o modelo que utilizou a otimização dinâmica do hiperparâmetro *gamma* alcançou a melhor performance, sugerindo que essa técnica pode ser uma solução eficaz para desafios de classificação em cenários similares.

Embora o conjunto de dados utilizado tenha sido relativamente pequeno, os resultados preliminares são encorajadores e indicam o potencial de expansão deste estudo para conjuntos de dados maiores. Além disso, os experimentos demonstraram que o uso de redes neurais leves e eficientes, como a *resnet50-fpn*, podem viabilizar o uso de aprendizado profundo em ambientes com recursos computacionais restritos, mantendo ainda uma boa precisão.

Como trabalhos futuros, propomos a ampliação do conjunto de dados e a investigação de outros métodos de pré-processamento de imagens multiespectrais. Esperamos que este estudo contribua para a implementação de tecnologias avançadas na conservação do Cerrado, auxiliando na preservação e recuperação desse bioma vital.



(a) Comparação entre melhores F1-score das espécies nos modelos com imagens RGB e multispectrais com função de perda otimizada



(b) Comparação entre F1-scores médios das espécies nos modelos com imagens RGB e multispectrais com função de perda otimizada

Fig. 6: Comparação de F1-scores das espécies entre modelos com imagens RGB e multispectrais, com e sem otimização da função de perda. A linha em Azul representa o modelo para imagens RGB e a linha em verde representa o modelo para as imagens multispectrais, ambas sem otimização da função de perda. A linha vermelha representa o modelo proposto, com imagens de entrada multispectrais e otimização da função de perda

REFERÊNCIAS

- [1] N. Myers, et al., "Biodiversity hotspots for conservation priorities," *Nature*, vol. 403, no. 6772, pp. 853-858, 2000.
- [2] C. A. Klink and A. G. Moreira, "The future of the Brazilian Cerrado," *Science*, vol. 307, no. 5707, pp. 1043-1044, 2005.
- [3] COSTA, F. G. da; COSTA, V. S. da .; MARTINS, I. da S.; BRITO, E. C. .; SOARES, K. S. A. .; CASTRO, Y. A. de A.; CASTRO, Ícaro F. de A. . Knowing Cerrado: field classes and their importance for environmental knowledge and preservation . Research, Society and Development, [S. l.], v. 9, n. 10, p. e1589108201, 2020. DOI: 10.33448/rsd-v9i10.8201.
- [4] Ouattara, T.A.; Sokeng, V.-C.J.; Zo-Bi, I.C.; Kouamé, K.F.; Grinand, C.; Vaudry, R. Detection of Forest Tree Losses in Côte d'Ivoire Using Drone Aerial Images. *Drones* 2022, 6, 83. <https://doi.org/10.3390/drones6040083>
- [5] H. G. Park, J. P. Yun, M. Y. Kim and S. H. Jeong, "Multichannel Object Detection for Detecting Suspected Trees With Pine Wilt Disease Using Multispectral Drone Imagery," in *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 14, pp. 8350-8358, 2021, doi: 10.1109/JSTARS.2021.3102218. keywords: Vegetation;Drones;Vegetation mapping;Image edge detection;Cameras;Indexes;Training;Convolutional neural network (CNN);deep learning;drone;multispectral;pine wilt disease (PWD);remote sensing.
- [6] Yu, X.; Hyypä, J.; Litkey, P.; Kaartinen, H.; Vastaranta, M.; Holopainen, M. Single-Sensor Solution to Tree Species Classification Using Multispectral Airborne Laser Scanning. *Remote Sens.* 2017, 9, 108. <https://doi.org/10.3390/rs9020108>
- [7] DJI Corp., Shenzhen, China. <https://ag.dji.com/pt-br/mavic-3-m>
- [8] S. Yahyanejad, J. Misiorny, and B. Rinner, "Lens distortion correction for thermal cameras to improve aerial imaging with small-scale UAVs," in *Proc. IEEE Int. Symp. Robot. Sensors Environ.*, 2011, pp. 231-236.
- [9] E. Karami, S. Prasad, and M. Shehata, "Image matching using SIFT, SURF, BRIEF and ORB: performance comparison for distorted images," *Newfoundland Electrical Comput. Eng. Conf.*, 2015
- [10] J E. Karami, S. Prasad, and M. Shehata, "Image matching using SIFT, SURF, BRIEF and ORB: performance comparison for distorted images," *Newfoundland Electrical Comput. Eng. Conf.*, 2015
- [11] M. Loeve, *Probability Theory*, Van Nostrand, New York, NY, USA, 3rd edition, 1963.
- [12] C. He, Z. Li, L. Chen and J. Peng, "Identification of finger vein using neural network recognition research based on PCA," 2017 IEEE 16th International Conference on Cognitive Informatics & Cognitive Computing (ICCI*CC), Oxford, UK, 2017, pp. 456-460, doi: 10.1109/ICCI-CC.2017.8109788., keywords: Veins;Feature extraction;Principal component analysis;Artificial neural networks;Image segmentation;Thumb;biological features;finger vein;PCA;BP neural network
- [13] A. Mikolajczyk and M. Grochowski, "Data augmentation for improving deep learning in image classification problem," in *Proc. Int. Interdisciplinary Ph.D. Workshop*, 2018, pp. 117-122.
- [14] T.-Y. Lin, P. Goyal, R. B. Girshick, K. He, e P. Dollar, "Focal loss for dense object detection," *arXiv preprint arXiv:1708.02002*, 2017.
- [15] Y. LeCun, L. Bottou, Y. Bengio, e P. Haffner, "Gradient-based learning applied to document recognition," in *Proc. IEEE*, vol. 86, n. 11, pp. 2278-2324, 1998.
- [16] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.
- [17] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, pp. 436-444, 2015.
- [18] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, "Focal Loss for Dense Object Detection," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 42, no. 2, pp. 318-327, 2018.